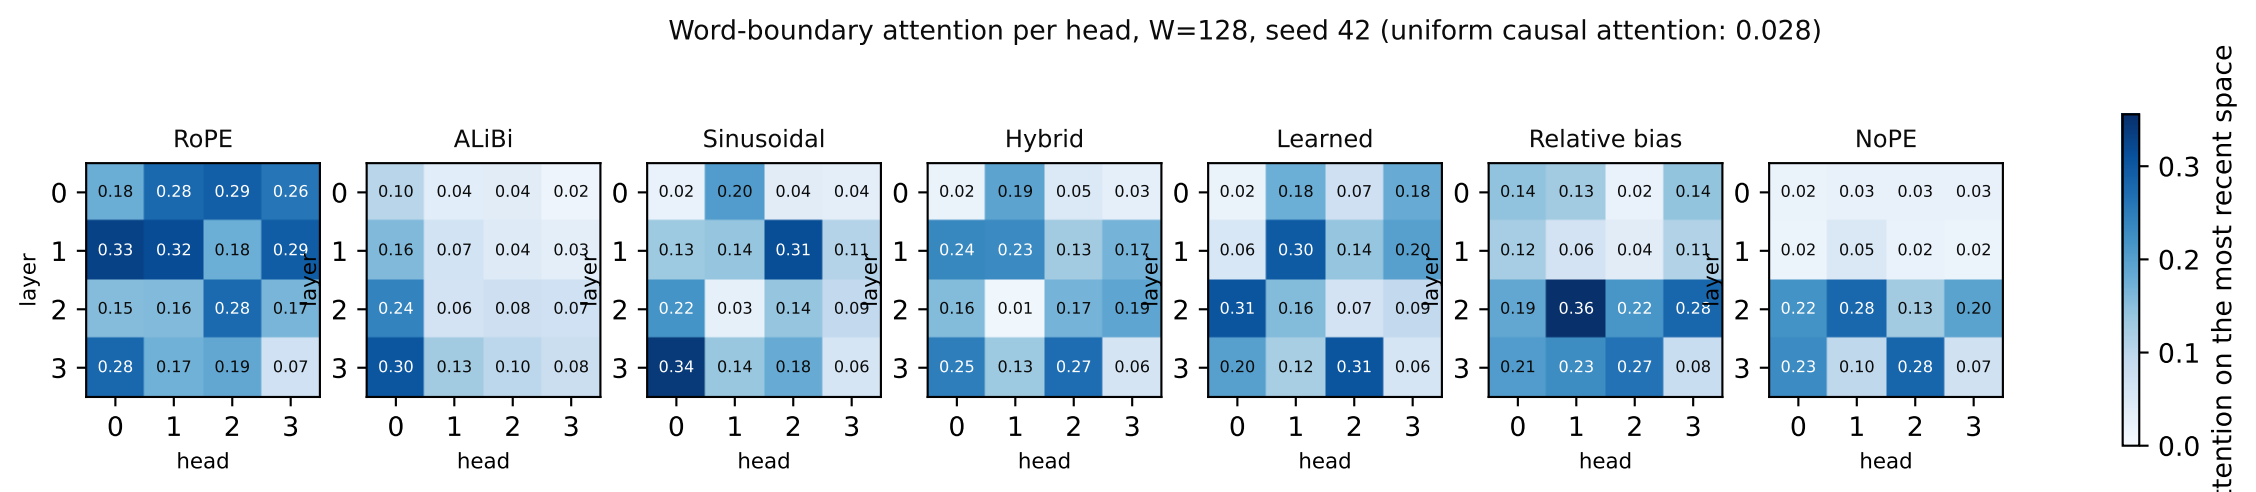
Word-boundary attention per head, W=128, seed 42 (uniform causal attention: 0.028)
RoPE
ALiBi
Sinusoidal
Hybrid
Learned
Relative bias
NoPE
layer
head
0.18 0.28 0.29 0.26
0.33 0.32 0.18 0.29
0.15 0.16 0.28 0.17
0.28 0.17 0.19 0.07
0.10 0.04 0.04 0.02
0.16 0.07 0.04 0.03
0.24 0.06 0.08 0.07
0.30 0.13 0.10 0.08
0.02 0.20 0.04 0.04
0.13 0.14 0.31 0.11
0.22 0.03 0.14 0.09
0.34 0.14 0.18 0.06
0.02 0.19 0.05 0.03
0.24 0.23 0.13 0.17
0.16 0.01 0.17 0.19
0.25 0.13 0.27 0.06
0.02 0.18 0.07 0.18
0.06 0.30 0.14 0.20
0.31 0.16 0.07 0.09
0.20 0.12 0.31 0.06
0.14 0.13 0.02 0.14
0.12 0.06 0.04 0.11
0.19 0.36 0.22 0.28
0.21 0.23 0.27 0.08
0.02 0.03 0.03 0.03
0.02 0.05 0.02 0.02
0.22 0.28 0.13 0.20
0.23 0.10 0.28 0.07
attention on the most recent space
0.0
0.1
0.2
0.3